SPRINGLOG-IA

Análisis de datos exploratorio (EDA)

Calidad de datos, distribución, patrones y dataset preparado

ENTREGABLE	03	**ESTUDIANTE**	David Felipe Rios Echeverri
ÁREA	Desarrollo Backend / Ingeniería de Software	**FECHA**	Octubre de 2026

Resumen ejecutivo

Se analizaron 500 registros sintéticos de payment-service entre 2026-10-01 00:29:10 y 2026-10-05 23:58:52. No se encontraron duplicados exactos en los campos originales. El CSV contenía 389 marcadores literales “None” en exception_type; no eran nulos CSV, por lo que se normalizaron a NO_APLICA. La distribución de clases está desbalanceada: INFO 60 % y CRITICAL 5 %.

1. Inventario y calidad de datos

Elemento	Resultado	Interpretación
Registros	500	500 filas en un microservicio sintético.
Atributos fuente	8	Ocho columnas originales con timestamp, contexto y mensaje.
Atributos limpios	11	Se añadieron date, hour y day_name para análisis temporal.
Duplicados exactos	0	Ninguno detectado en los registros procesados.
Nulos CSV reales	0 después de validación	El literal “None” de exception_type era un marcador textual, no un nulo real.
Marcadores de excepción ausente	389	Normalizados a NO_APLICA para evitar confusión al volver a leer el CSV.
Ventana temporal	2026-10-01 00:29:10 a 2026-10-05 23:58:52	Cinco días de registros sintéticos.

2. Distribución de severidad

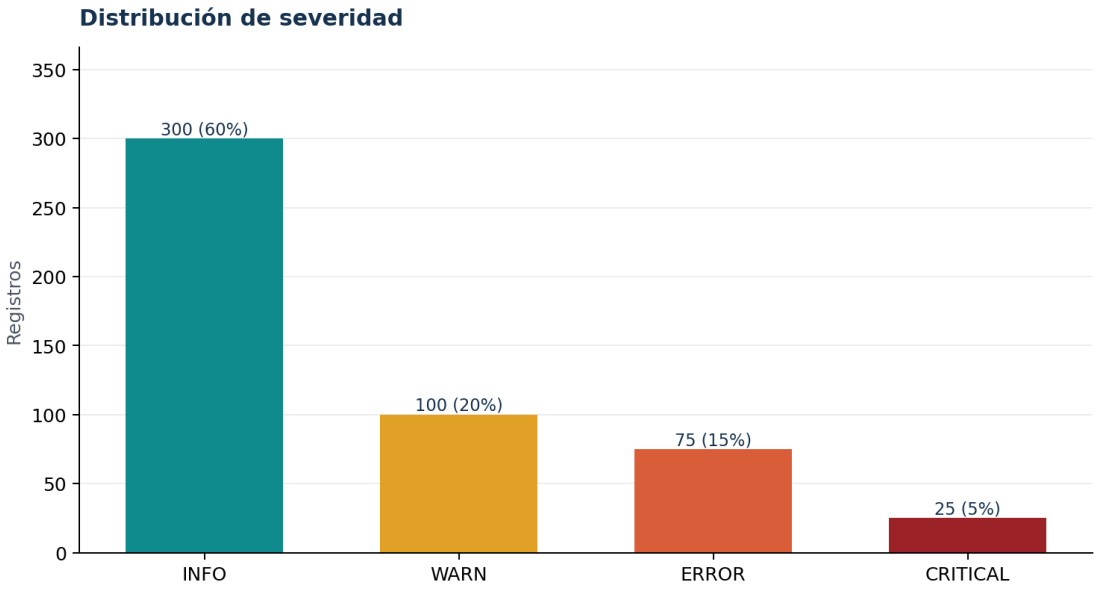


Figura 1. Distribución de severidades del dataset.

INFO representa 300/500 registros (60 %), WARN 100 (20 %), ERROR 75 (15 %) y CRITICAL 25 (5 %). El diseño deliberado de estas proporciones provoca un desequilibrio de clases que debe considerarse en el entrenamiento y la evaluación.

3. Distribución por instancia

Instancia	INFO	WARN	ERROR	CRITICAL	Total	%
instance-prod-east-01	67	30	31	7	135	27.0%
instance-prod-east-02	108	35	24	5	172	34.4%
instance-prod-west-01	125	35	20	13	193	38.6%

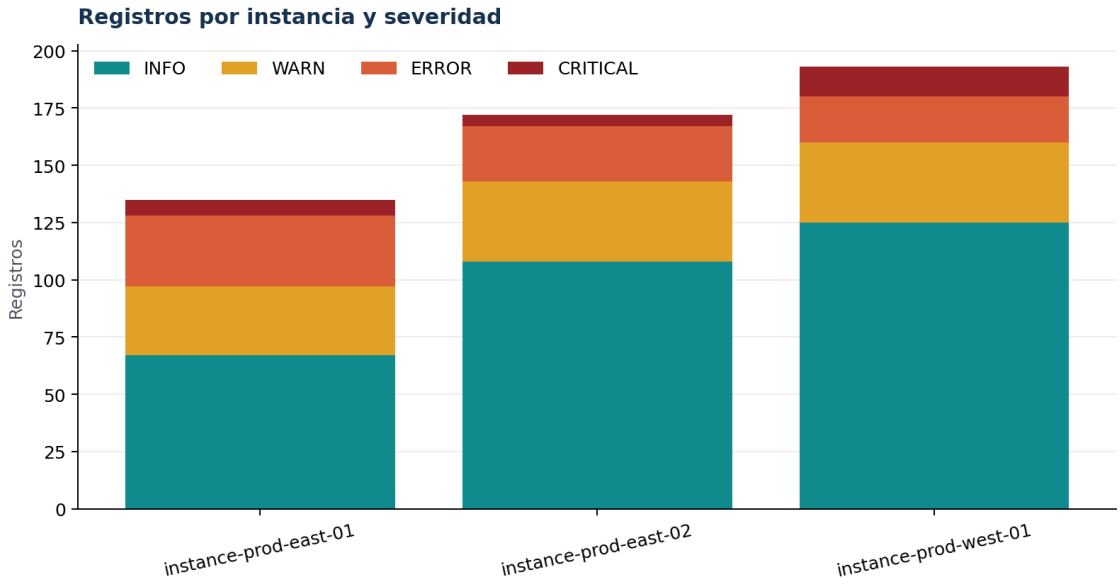


Figura 2. Distribución de severidad por instancia.

4. Patrones temporales y técnicos

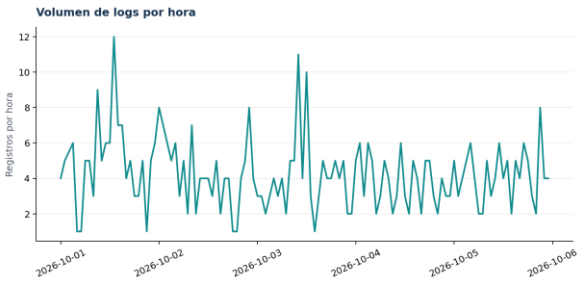


Figura 3. Volumen por hora.

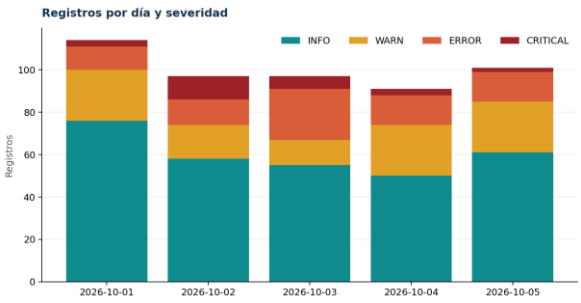


Figura 4. Eventos por día y severidad.

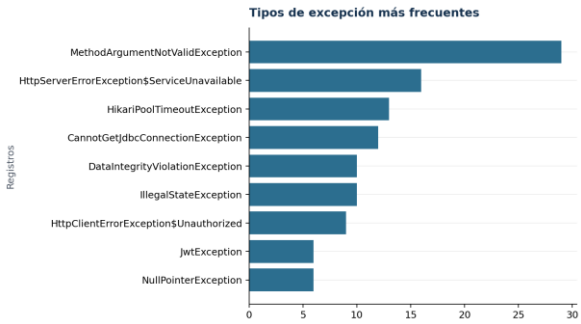


Figura 5. Excepciones más frecuentes.

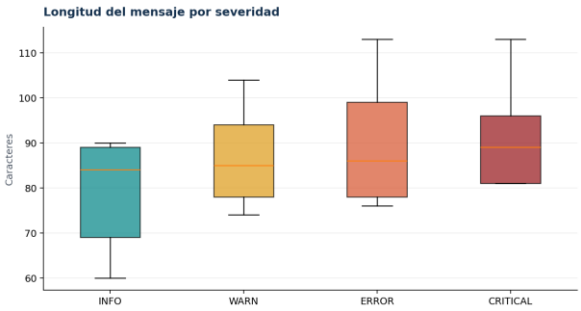


Figura 6. Longitud del mensaje por severidad.

Entre los tipos de excepción más frecuentes del conjunto figuran MethodArgumentNotValidException (29), HttpServerErrorException$ServiceUnavailable (16), HikariPoolTimeoutException (13) y CannotGetJdbcConnectionException (12). Estos conteos son observaciones de esta muestra sintética, no predicciones de tasa de fallos real.

5. Preparación para el modelo

- Convertir timestamp a fecha/hora y derivar date, hour y day_name para análisis exploratorio.
- Convertir el marcador literal None de exception_type a NO_APLICA; volver a comprobar que no existen celdas vacías.
- Sanitizar JWT/Bearer, tokens/secretos, correos, identificadores y números de tarjeta en los mensajes procesados.
- Mitigar atajos de etiquetado durante el modelado sustituyendo menciones textuales de niveles (INFO/WARN/ERROR/CRITICAL) por [LEVEL] en las características.
- Mantener la severidad como variable objetivo; no incluirla dentro del texto de entrada del clasificador.

6. Sesgos y limitaciones del EDA

La distribución se definió al crear los datos y los patrones técnicos están muy asociados a severidad. Por tanto, un modelo puede aprender reglas específicas de las plantillas sintéticas y obtener resultados que no se trasladan a logs reales. El conjunto no incluye telemetría de producción, etiquetas auditadas externamente ni datos suficientes para evaluar deriva temporal. La validación con mensajes nuevos y un conjunto etiquetado por expertos sigue siendo un requisito previo a producción.

Artefactos generados

El paquete incluye el CSV original en data/, la versión limpia payment_service_logs_500_clean.csv, el script 03_ANALISIS_DATOS.py, este reporte y el libro 03_ANALISIS_DATOS.xlsx.