SPRINGLOG-IA

Modelo o prototipo de IA

Clasificación supervisada de severidad con TF-IDF y Random Forest

ENTREGABLE	04	**ESTUDIANTE**	David Felipe Rios Echeverri
ÁREA	Desarrollo Backend / Ingeniería de Software	**FECHA**	Octubre de 2026

Resumen técnico

Se entrenó y evaluó un pipeline TF-IDF (unigramas/bigramas, máximo 1.000 características) + Random Forest de 100 árboles. En la partición de prueba estratificada de 100 registros obtuvo accuracy 93.0% y F1 macro 0.933. El artefacto de inferencia se guarda como springlog_random_forest.joblib.

1. Arquitectura del pipeline

Etapa	Implementación	Control o nota
Ingesta	CSV normalizado de payment-service.	Validación de columnas requeridas y severidades permitidas.
Sanitización	Regex para JWT/Bearer, secretos/tokens, correos, IDs y PAN.	La sanitización implementada es basada en patrones; no garantiza detectar todo secreto posible.
Representación	Concatenación de logger_class + exception_type + log_message.	Los valores de ausencia pasan a NO_APLICA; menciones de severidad se enmascaran como [LEVEL].
Vectorización	TF-IDF con n-gramas (1,2), max_features=1000 y sublinear_tf=True.	El vectorizador se ajusta solo en el conjunto de entrenamiento durante evaluación.
Clasificador	RandomForestClassifier(n_estimators=100, class_weight=balanced, random_state=42).	Se conserva como baseline por continuidad del proyecto; no es el algoritmo de mayor puntuación en esta muestra.

2. Proceso de entrenamiento y comparación

La evaluación utiliza train_test_split con test_size=0.20, stratify=y y random_state=42: 400 registros para entrenamiento y 100 para prueba. Se comparan cuatro clasificadores sobre la misma representación textual.

Modelo	Accuracy	Precisión macro	Recall macro	F1 macro
Random Forest (100 árboles)	93.0%	0.974	0.912	0.933
Regresión logística	100.0%	1.000	1.000	1.000
Naive Bayes multinomial	100.0%	1.000	1.000	1.000
Árbol de decisión	98.0%	0.992	0.975	0.983

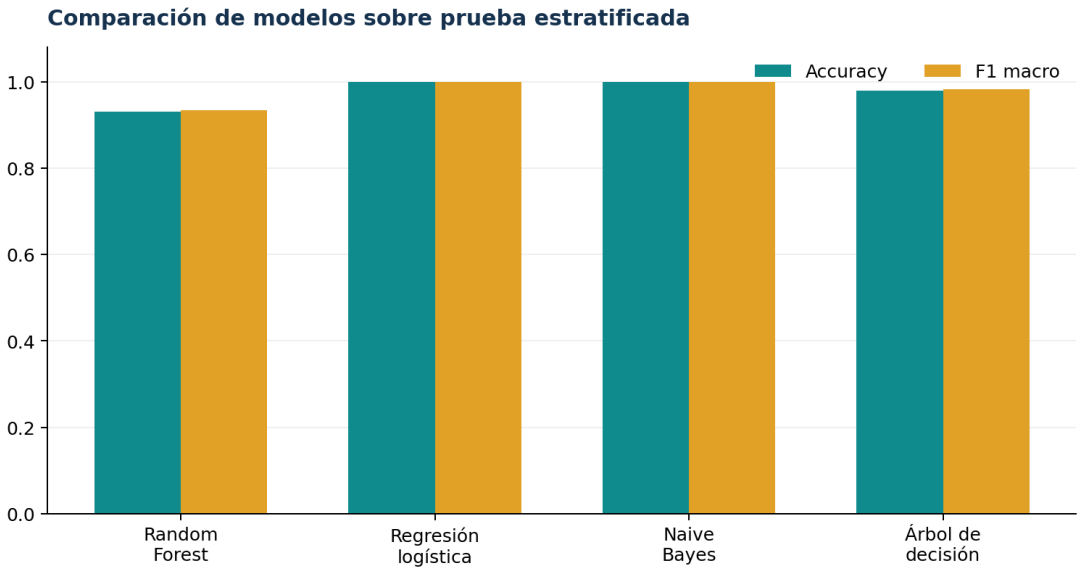


Figura 1. Comparación de los cuatro modelos sobre la misma partición.

Interpretación de la comparación

Regresión logística y Naive Bayes alcanzaron 100 % en esta partición, y el árbol de decisión 98 %. En una muestra sintética con patrones muy regulares, resultados perfectos son una señal para ampliar la validación, no una garantía de generalización. Se mantiene Random Forest como prototipo de referencia, sin afirmar que supere a los demás modelos.

3. Desempeño del modelo de referencia

Clase	Precisión	Recall	F1	Soporte
CRITICAL	1.00	1.00	1.00	5
ERROR	1.00	1.00	1.00	15
INFO	0.90	1.00	0.94	60
WARN	1.00	0.65	0.79	20
Macro promedio	0.97	0.91	0.93	100
Promedio ponderado	0.94	0.93	0.92	100

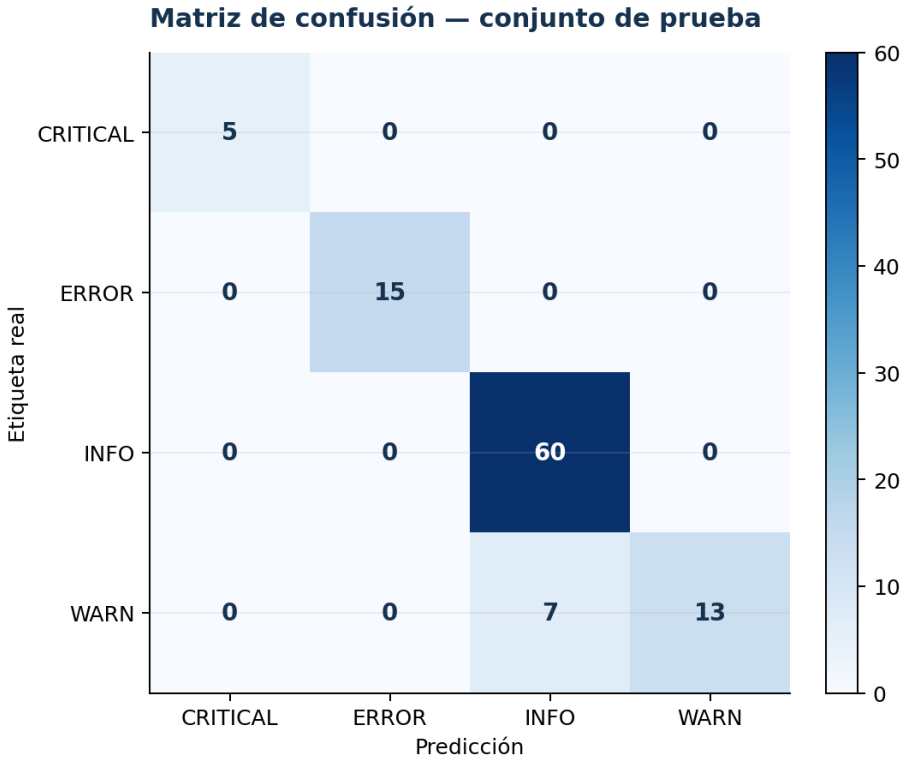


Figura 2. Filas = clase real; columnas = clase predicha. Orden: CRITICAL, ERROR, INFO, WARN.

4. Ejemplo de predicción y uso

Entrada de demostración (mensaje sintético sanitizado): “com.empresa.payment.repository.TransactionRepository HikariPoolTimeoutException [LEVEL] database connection pool exhausted pool=HikariPool-1 timeoutMs=30000 activeConnections=20 maxPoolSize=20”. El script prepara el texto de entrada del mismo modo que durante entrenamiento y genera una etiqueta predicha. La salida es una clasificación, no un diagnóstico definitivo de causa raíz.

5. Medición de inferencia local

En la ejecución registrada se midieron predicciones individuales en este entorno local sobre 30 registros de prueba: mediana 21.5 ms y percentil 95 23.6 ms por registro. Es una medición orientativa, dependiente del hardware y carga; no equivale al MTTR ni a latencia de un servicio de producción.

6. Limitaciones y trabajo futuro

- La muestra sintética y sus plantillas asociadas a severidad pueden exagerar el desempeño fuera de muestra.
- La clasificación de WARN es el principal punto débil: recall 65 %; 7 de 20 WARN se predijeron como INFO.
- No se implementa integración online con Logback/Log4j2, Prometheus o Grafana.
- Antes de producción, medir generalización en plantillas nuevas, revisar datos con expertos, calibrar umbrales y mantener supervisión humana.
- El pipeline serializado usa como entrada una lista de cadenas combinadas y sanitizadas; el README explica el contrato de inferencia.