SPRINGLOG-IA

Evaluación de resultados y validación

Métricas, casos borde y alcance de las conclusiones

ENTREGABLE	05	**ESTUDIANTE**	David Felipe Rios Echeverri
ÁREA	Desarrollo Backend / Ingeniería de Software	**FECHA**	Octubre de 2026

Resultado principal

Random Forest obtuvo 93.0% de accuracy, F1 macro 0.933 y F1 ponderado 0.925 sobre 100 registros de prueba. Detectó 5/5 ejemplos CRITICAL y 15/15 ERROR, mientras que clasificó 7 de los 20 WARN como INFO. La muestra es sintética y pequeña.

1. Diseño de evaluación

Elemento	Configuración
Dataset total	500 registros sintéticos de payment-service.
Partición	80 % entrenamiento (400) / 20 % prueba (100), estratificada.
Reproducibilidad	random_state=42; TF-IDF se ajusta dentro del pipeline y sobre entrenamiento.
Métrica principal	F1 macro junto con accuracy y métricas por clase, para no ocultar errores en clases minoritarias.
Auditoría auxiliar	Se exportan 25 casos estratificados del test para revisión textual. No equivale a auditoría independiente realizada por un experto de producción.

2. Métricas globales y por clase

Indicador	Valor	Interpretación
Accuracy	93.0%	93 de 100 predicciones correctas.
Precision macro	0.974	Promedio de precisión por clase.
Recall macro	0.912	Promedio de sensibilidad por clase.
F1 macro	0.933	Métrica principal sensible a desempeño en clases minoritarias.
F1 ponderado	0.925	Promedio ponderado por el soporte de las clases.
CRITICAL recall	100 % (5/5)	Sin omisiones CRITICAL en esta partición; soporte solo cinco casos.
ERROR recall	100 % (15/15)	Todos los ERROR de prueba detectados; no garantiza desempeño fuera de la muestra.
WARN recall	65 % (13/20)	7 de 20 WARN fueron clasificados como INFO.

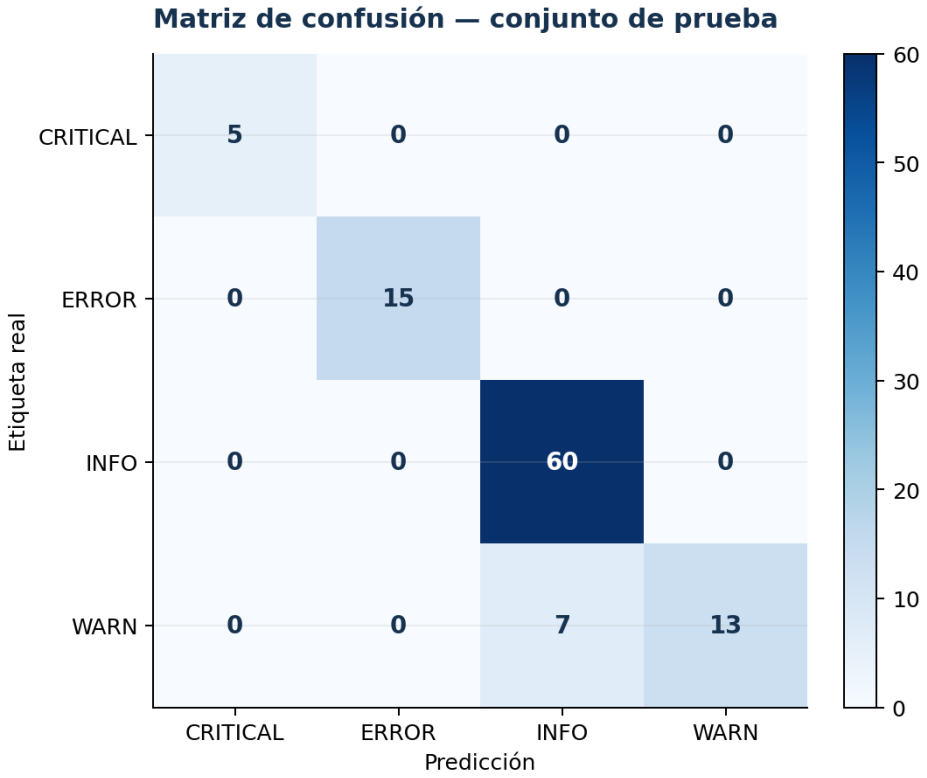


Figura 1. Matriz de confusión de Random Forest.

3. Casos borde

El error observado se concentra en WARN que se confunden con INFO. En la matriz, 7 WARN se predicen como INFO; no se observan errores CRITICAL→INFO ni ERROR→INFO en la partición. Esto describe solo el conjunto de prueba y no debe expresarse como garantía de seguridad operacional.

- Posible causa: logs WARN sin excepción explícita pueden compartir vocabulario con mensajes rutinarios; el modelo textual no utiliza durationMs como variable numérica independiente.
- Mejora técnica: extraer duración, estado HTTP, intentos de reintento y métricas del pool como variables estructuradas.
- Mejora de validación: mantener un conjunto temporal o por plantilla que no se use en entrenamiento y realizar revisión por ingeniero backend/SRE.

4. Comparación antes/después y efecto operativo

No existe todavía una medición experimental del tiempo de diagnóstico antes y después de utilizar SpringLog-IA. El tiempo de inferencia del modelo (mediana 21.5 ms/registro en el entorno de prueba) mide una etapa computacional, no el tiempo de resolución del incidente. Las cifras de reducción del MTTR deben mantenerse como hipótesis hasta ejecutar un piloto con tareas comparables y medir tiempo de diagnóstico, falsa alerta y omisiones.

5. Recomendaciones

- Validar las etiquetas con dos revisores de dominio y registrar desacuerdos.
- Expandir la muestra con mensajes sintéticos de plantillas nuevas y luego con logs reales anonimizados.
- Comparar Random Forest con regresión logística y Naive Bayes sobre prueba temporal o por grupo, no solo un split aleatorio.
- Medir la latencia del pipeline completo, incluidos lectura, sanitización, vectorización y emisión de alertas.

6. Muestra de 25 predicciones para auditoría

La siguiente tabla resume una selección estratificada de la partición de prueba. “Coincide” compara la predicción con la etiqueta del CSV; la revisión humana de los casos debe confirmar si la etiqueta de referencia describe correctamente el contenido técnico. La etiqueta sintética no constituye por sí misma un ground truth independiente.

ID	Real	Predicción	Coincide	Conf.	Fragmento de log sanitizado
#008	INFO	INFO	Sí	1.00	POST /api/v1/payments returned status=201 ...
#020	WARN	WARN	Sí	0.56	Database connection acquisition latency el...
#023	INFO	INFO	Sí	1.00	Idempotency key accepted key=[REDACTED] tr...
#025	WARN	WARN	Sí	1.00	Retrying transient payment gateway failure...
#026	INFO	INFO	Sí	0.99	Payment gateway response received transact...
#036	WARN	INFO	No	0.51	Payment gateway response slower than thres...
#047	INFO	INFO	Sí	1.00	JWT authentication successful subject=user...
#049	WARN	INFO	No	0.51	Payment gateway response slower than thres...
#050	INFO	INFO	Sí	1.00	Transaction lookup completed transactionId...
#051	INFO	INFO	Sí	1.00	Scheduled reconciliation completed checked...
#060	WARN	INFO	No	0.67	Payment processing approaching timeout tra...
#062	WARN	WARN	Sí	1.00	Retrying transient payment gateway failure...
#071	WARN	WARN	Sí	1.00	Database connection pool utilization high ...
#138	CRITICAL	CRITICAL	Sí	0.99	CRITICAL database connection pool exhauste...
#146	ERROR	ERROR	Sí	1.00	Payment state transition rejected transact...
#159	CRITICAL	CRITICAL	Sí	0.97	CRITICAL JWT verification failures exceede...
#183	CRITICAL	CRITICAL	Sí	0.97	CRITICAL JWT verification failures exceede...
#187	ERROR	ERROR	Sí	0.81	Failed to acquire database connection oper...
#214	CRITICAL	CRITICAL	Sí	0.86	CRITICAL payment persistence unavailable; ...
#266	ERROR	ERROR	Sí	0.79	Payment gateway unavailable status=503 tra...
#283	ERROR	ERROR	Sí	0.79	Payment gateway unavailable status=503 tra...
#306	CRITICAL	CRITICAL	Sí	0.99	CRITICAL database connection pool exhauste...
#308	ERROR	ERROR	Sí	1.00	Payment gateway authentication failed stat...
#321	ERROR	ERROR	Sí	1.00	Payment state transition rejected transact...
#326	ERROR	ERROR	Sí	0.93	REST request validation failed field=payme...