SPRINGLOG-IA

Análisis ético, gobernanza y viabilidad de negocio

Privacidad, sesgo, supervisión humana, riesgos y escenario económico

ENTREGABLE	06	**ESTUDIANTE**	David Felipe Rios Echeverri
ÁREA	Desarrollo Backend / Ingeniería de Software	**FECHA**	Octubre de 2026

Conclusión ejecutiva

El valor potencial de SpringLog-IA es acelerar la priorización de logs sin ceder el control operativo al modelo. La viabilidad técnica requiere validación en logs reales; las cifras económicas de este informe son un escenario ilustrativo basado en supuestos explícitos, no beneficios observados.

1. Privacidad y gobernanza de datos

Los logs de backend pueden contener JWT/Bearer, tokens, contraseñas, secretos, correos, identificadores de usuario y datos de tarjeta. El script del proyecto incluye reglas Regex deterministas para enmascarar patrones comunes antes de vectorizar los mensajes; estas reglas reducen riesgo, pero no garantizan detección de todos los datos sensibles.

Riesgo	Control en el prototipo	Limitación residual
JWT, bearer o tokens	Reemplazo por marcadores REDACTED.	Tokens con formatos no previstos pueden escapar.
Contraseñas y API keys	Reglas para campos clave-valor comunes.	Revisar variantes y formatos multilinea en una implementación real.
Correos, IDs y PAN	Sustitución de email, userId/customerId y card/PAN.	Las regex no clasifican por contexto y pueden no cubrir todas las variantes.
Envío a servicios externos	Recomendación de sanitizar localmente antes de invocar APIs.	La exploración generativa no es una integración desplegada.
Retención y acceso	Propuesta de control de acceso, minimización y retención limitada.	Debe concretarse en políticas y controles de la organización.

El diseño toma como referencias la Ley 1581 de 2012 y principios de seguridad y minimización de datos. Este informe no certifica cumplimiento legal; la aplicación concreta debe revisarse con responsables de privacidad y seguridad según el contexto del tratamiento.

2. Sesgos, error y supervisión humana

El dataset tiene 60 % INFO y solo 5 % CRITICAL. El uso de class_weight=balanced y el reporte de F1 macro ayudan a observar el rendimiento por clase, pero no eliminan el sesgo de una muestra sintética. Además, las clases están asociadas a patrones técnicos que pueden ser demasiado fáciles de aprender.

- Human-in-the-loop: las etiquetas son recomendaciones; los incidentes críticos y las predicciones de baja confianza se revisan por un ingeniero.
- Explicabilidad: conservar el log sanitizado, la clase predicha, la confianza y la versión del modelo; no interpretar la clasificación como causa raíz.

- Gobernanza: asignar responsable de modelo y responsable operativo, versionar datos/código y definir procedimiento de rollback.
- Monitoreo: medir falsos negativos de severidad, tasa de WARN degradados a INFO, latencia y cambios en la distribución de logs.

3. Matriz de riesgos

Riesgo	Prob.	Impacto	Mitigación / responsable
WARN degradado a INFO	Alta	Medio-alto	Ajustar features y umbrales; revisar por SRE.
Falso negativo CRITICAL con logs reales	Media	Alto	No confiar en el modelo como único alerta; mantener reglas de guardia.
Datos sensibles no detectados por regex	Media	Alto	Ampliar pruebas, validar con seguridad, bloquear salida en duda.
Degradación por cambio de plantilla	Alta	Medio	Monitorizar deriva y reentrenar con conjunto etiquetado.
ROI sobreestimado	Alta	Medio	Medir piloto y usar costos/volúmenes reales; finanzas/operaciones.
Modelo no reproducible	Baja-media	Medio	Versionar dataset, dependencias, semilla, métricas y artefacto.

4. Escenario económico ilustrativo

Para explorar la magnitud del beneficio potencial se reutilizan supuestos de trabajo del proyecto: cinco desarrolladores, 40 incidentes al mes por desarrollador, 35 minutos recuperados por incidente y un costo de oportunidad de USD 35 por hora. El escenario no se ha validado con mediciones reales de SpringLog-IA.

Concepto	Cálculo
Minutos recuperados al mes	5 × 40 × 35 = 7.000 min
Horas recuperadas al mes	7.000 / 60 = 116,67 h
Ahorro bruto mensual	116,67 h × USD 35 = USD 4.083,33
Costo operativo mensual supuesto	USD 50,00
Ahorro neto mensual estimado	USD 4.033,33
Ahorro neto anual antes de inversión	USD 4.033,33 × 12 = USD 48.400,00
Inversión inicial supuesta	USD 1.500,00
Beneficio primer año después de inversión	USD 48.400 − USD 1.500 = USD 46.900
ROI simple del primer año	USD 46.900 / USD 1.500 ≈ 3.127 %
Payback aproximado	USD 1.500 / USD 4.033,33 × 30 ≈ 11,2 días

Condición de uso

Estas cifras no deben presentarse como resultados medidos. El beneficio depende, entre otras variables, del volumen real de incidentes, del tiempo realmente ahorrado, de falsos positivos/negativos y del costo operativo efectivo.

5. Sostenibilidad y viabilidad técnica

Un clasificador scikit-learn ejecutado localmente puede evitar enviar cada log a un LLM externo, pero no se ha medido energía ni huella de carbono en este proyecto. No se afirma un porcentaje de reducción de CO_2e. Una futura comparación Green AI debe medir ambos enfoques bajo las mismas tareas, hardware, carga, calidad de salida y ventana de tiempo.

6. Plan de implementación

- Fase 1 — Validación offline: ampliar dataset y etiquetas; medir métricas por clase y por plantilla.
- Fase 2 — Piloto sombreado: procesar logs ya sanitizados sin afectar alertas de producción y comparar con decisiones de SRE.
- Fase 3 — Observabilidad: exponer métricas del clasificador, registrar versión/confianza y definir umbrales revisados por operación.
- Fase 4 — Decisión de adopción: evaluar MTTR real, costo, privacidad, tasa de fallos y beneficio neto antes de activar alertas asistidas.